

BANQUE 360

Projet Data Analyst complet - SQL Server et Power BI

Architecture raw / staging / mart • Power Query • Modèle en étoile • DAX • Dashboard

Architecture de bout en bout - Banque 360



Livable - Documentation complète du projet finalisé et prêt à être publié sur GitHub.

Benjamin Baillet

Portfolio Data Analyst - Août 2026

1. Synthèse exécutive

Banque 360 est un projet décisionnel de bout en bout simulant le pilotage d'une banque régionale de 25 agences. Il couvre toutes les étapes attendues d'un projet Data Analyst : compréhension du besoin, ingestion des données, contrôle qualité, nettoyage, modélisation analytique, préparation Power BI, calcul d'indicateurs et restitution décisionnelle.

Chaîne complète - 7 fichiers CSV -> SQL Server -> raw -> staging -> mart -> Power Query -> modèle Power BI -> DAX -> rapport interactif.

Bloc	Livrable final
SQL Server	Base Banque360, schémas structurés, tables raw/staging/mart, contrôles et index.
Modèle analytique	4 dimensions, 5 faits, grains explicites et gestion des références inconnues.
Power BI	9 tables mart, 17 relations, table de dates, clés techniques masquées.
DAX	45 mesures métier initiales, complétées par des mesures clients et de mise en forme.
Rapport	5 pages principales, une page de contrôle masquée et un détail agence par extraction.
GitHub	README, structure de dépôt, documentation PDF, captures et instructions de reproduction.

Le projet est conçu pour être compris rapidement par un recruteur tout en restant suffisamment détaillé pour être défendu techniquement en entretien.

2. Contexte métier et objectifs

La banque fictive souhaite disposer d'un outil de pilotage unique pour rapprocher activité commerciale, portefeuille clients, crédits, remboursements et objectifs d'agences.

- Suivre la dynamique des transactions, les débits, les crédits et les frais générés.
- Mesurer la production de crédit, les montants moyens, les taux et le risque à l'octroi.
- Analyser les segments clients, les tranches de revenus et les niveaux de risque.
- Détecter les impayés, les retards et les montants non recouvrés.
- Comparer le réalisé aux objectifs de revenu, de crédit et d'acquisition.
- Identifier les agences performantes et celles nécessitant une analyse détaillée.

Positionnement - Le projet démontre la capacité à transformer des fichiers bruts imparfaits en un outil de décision cohérent, fiable et documenté.

3. Sources de données et volumétrie

Domaine	Volume brut	Utilité
Agences	25	Géographie, catégorie, effectif et date d'ouverture.
Produits	10	Famille, univers et niveau de complexité.
Clients	6 060 lignes	Profil, segment, revenu, score de risque et agence.
Transactions	15 150 lignes	Flux, canal, produit, frais, devise et statut.
Crédits	600 lignes	Montant, taux, durée, mensualité et score de risque.
Remboursements	18 899 lignes	Échéances, paiements, impayés et jours de retard.
Objectifs agences	1 050 lignes	Objectifs mensuels et seuils de suivi.

3.1 Anomalies réalistes intégrées


- 60 doublons de clients et 150 doublons de transactions.
- 40 dates de transaction impossibles ou non convertibles.
- Courriels et codes postaux manquants.
- Revenus, taux de crédit ou paiements négatifs.
- Clés agence, produit ou crédit orphelines.
- Variantes de casse, d'accents et de libellés dans les statuts.

3.2 Principes de traitement

Les données brutes ne sont jamais corrigées directement. Les anomalies sont détectées, documentées et traitées dans les couches suivantes. Les références inconnues sont conservées grâce à une clé technique 0 plutôt que supprimées.

4. Architecture technique

Architecture de bout en bout - Banque 360



Outil	Rôle
Docker Desktop	Exécute SQL Server 2022 et conserve la base dans un environnement isolé.
VS Code	Édition, exécution et versionnement des scripts T-SQL.
VMware Fusion	Exécute Windows 11 sur le Mac.
Power BI Desktop	Power Query, modèle sémantique, DAX et visualisations.
GitHub	Publication, documentation et présentation du projet aux recruteurs.

5. Partie SQL Server

5.1 Création de la base et des schémas

La base Banque360 est créée sous SQL Server 2022. Les schémas séparent les responsabilités : raw pour le brut, staging pour les données propres, mart pour l'analytique et reporting pour une interface stable éventuelle.

Schéma	Rôle
raw	Conserver les fichiers importés sans transformation métier.
staging	Nettoyer, typer, normaliser et dédupliquer les données.
mart	Construire le modèle en étoile destiné à l'analyse.
reporting	Exposer des objets de restitution stables lorsque nécessaire.

5.2 Import des fichiers CSV

Les fichiers sont copiés dans le conteneur SQL Server puis chargés avec BULK INSERT. L'encodage UTF-8 est conservé afin de gérer correctement les accents. Les tables raw utilisent des types permissifs pour éviter de perdre des lignes lors de l'import.

```
BULK INSERT raw.nom_table
FROM '/var/opt/mssql/import/fichier.csv'
WITH (
    FORMAT = 'CSV',
    FIRSTROW = 2,
    FIELDQUOTE = '',
    CODEPAGE = '65001'
);
```

5.3 Contrôles qualité

Avant toute correction, les scripts de contrôle recensent les doublons, les dates invalides, les valeurs négatives, les données manquantes et les clés orphelines. Cette étape permet de comprendre les anomalies plutôt que de les masquer.


5.4 Nettoyage staging

- Conversion contrôlée des dates, nombres et booléens.
- Normalisation des textes, statuts et identifiants.
- Déduplication selon les clés métier et l'ordre des sources.
- Mise à NULL ou rejet des valeurs impossibles selon la règle métier.
- Conservation de la traçabilité entre source, ligne brute et ligne propre.

5.5 Construction du mart

Les tables staging alimentent quatre dimensions et cinq tables de faits. Les clés techniques entières allègent les relations et rendent possible l'utilisation d'un membre inconnu avec clé 0.

Modèle analytique en étoile



6. Modèle analytique et grains

6.1 Dimensions

Dimension	Grain	Axes
dim_date	Une ligne par date	Année, semestre, trimestre, mois, semaine et jour.
dim_agence	Une ligne par agence	Ville, département, région, catégorie et effectif.
dim_client	Une ligne par client	Segment, profession, revenu, risque, statut et localisation.
dim_produit	Une ligne par produit	Produit, famille, univers et niveau de complexité.

6.2 Tables de faits

Fait	Grain	Mesures principales
fact_transactions	Une ligne par transaction	Montant signé, débit, crédit, frais, statut et canal.
fact_credits	Une ligne par crédit	Montant initial, taux, durée, mensualité et risque.
fact_remboursements	Une ligne par échéance	Attendu, payé, non payé, retard et impayé.
fact_objectifs_agences	Une ligne par agence et mois	Objectifs de revenu, crédit, clients et seuil d'impayé.
fact_entrees_clients	Une ligne par entrée client	Nombre réel de nouveaux clients.

Pourquoi le grain est crucial - Il empêche les doublons et les doubles comptages, notamment lorsqu'une même agence, un même client ou une même date filtre plusieurs faits.

6.3 Contrôle final SQL

- Présence des tables staging et mart.
- Volumétrie des dimensions et des faits.
- Présence des membres inconnus avec clé 0.
- Unicité des clés métier.
- Respect du grain de chaque table.
- Conservation des lignes et des montants.
- Intégrité des clés étrangères et présence des index.
- Synthèse finale indiquant ÉTAPE 7 VALIDÉE.

7. Partie Power BI - environnement et connexion

Power BI Desktop est exécuté dans Windows 11 via VMware Fusion. SQL Server reste actif dans Docker sur le Mac pendant la connexion et les actualisations.

1. Démarrer Docker Desktop et le conteneur SQL Server.
2. Démarrer Windows 11 dans VMware Fusion.
3. Tester l'accès au port 1433 depuis Windows.
4. Dans Power BI, choisir le connecteur Base de données SQL Server.
5. Utiliser ADRESSE_IP_DU_MAC,1433 et la base Banque360.
6. Choisir le mode Importer.
7. Sélectionner uniquement les 9 tables du schéma mart.
8. Cliquer sur Transformer les données avant le chargement.

Sécurité - Le mot de passe SQL et les informations sensibles ne doivent apparaître ni dans GitHub, ni dans les captures, ni dans la documentation publique.

8. Préparation Power Query

8.1 Organisation des requêtes

Les requêtes sont rangées dans deux groupes : 01_Dimensions et 02_Faits. Cette organisation n'altère pas les données mais rend le projet lisible et professionnel.

8.2 Profilage et typage

- Activation de la qualité, de la distribution et du profil des colonnes.
- Vérification des clés en nombres entiers.
- Vérification des dates, des montants décimaux et des indicateurs Vrai/Faux.
- Contrôle des valeurs NULL prévues, notamment sur certaines dates de paiement.

8.3 Colonnes de présentation créées

Colonne	Table	Utilité
agence_libelle	dim_agence	Combiner identifiant et nom de l'agence.
produit_libelle	dim_produit	Combiner identifiant et nom du produit.
tranche_revenu	dim_client	Segmenter les clients selon le revenu mensuel.
niveau_risque	dim_client	Classer les clients en risque faible, modéré ou élevé.

8.4 Répartition des responsabilités

Couche	Responsabilité
SQL Server	Nettoyage structurel, règles métier, rejets, contrôle et modèle analytique.
Power Query	Préparation de la couche de présentation, types, libellés et attributs analytiques.
DAX	Calculs dynamiques qui réagissent au contexte de filtre du rapport.

9. Modèle Power BI

- 9 tables mart importées.
- 17 relations au total : 15 actives et 2 inactives.
- Relations 1 vers plusieurs avec filtrage à sens unique.
- dim_date marquée comme table de dates avec date_complete.
- Tri de nom_mois par mois_numero et de annee_mois_libelle par annee_mois.
- Clés techniques masquées pour l'utilisateur du rapport.
- Relations secondaires de date activées avec USERELATIONSHIP dans les mesures concernées.

Relations inactives - La date de fin prévue des crédits et la date réelle de paiement des remboursements ne peuvent pas être actives simultanément avec les dates principales. Elles sont donc activées mesure par mesure.

10. Mesures DAX

La table _Mesures centralise les calculs et les organise en cinq dossiers. Le projet comprend 45 mesures métier initiales, puis des mesures complémentaires dédiées aux clients et à la mise en forme conditionnelle.

Dossier	Contenu
01 - Transactions	Volumes, débits, crédits, flux net, frais, montant moyen et rejets.
02 - Crédits	Production, montants moyens, taux, mensualités, score de risque et date de fin.
03 - Remboursements	Échéances, impayés, retards, montants, recouvrement et date de paiement.
04 - Objectifs et clients	Nouveaux clients, objectifs, écarts, taux de réalisation et profil clients.
05 - Temps	Comparaisons N-1, évolutions et relations de dates alternatives.

10.1 Exemples de mesures

```
Taux de retard =
DIVIDE(
    [Nb retards],
    [Nb échéances]
)
```

```
Taux réalisation production crédit =
DIVIDE(
    [Production crédit],
    [Objectif production crédit]
)
```

```
Production par date de fin =
CALCULATE(
    [Production crédit],
    USERELATIONSHIP(
        'mart fact_credits'[date_fin_prevue_key],
        'mart dim_date'[date_key]
    )
)
```

10.2 Différence entre impayé et retard

Un impayé correspond à une échéance non réglée. Un retard correspond à une échéance payée après la date prévue. Les indicateurs est_impaye et est_en_retard sont donc distincts et alimentent des mesures différentes.

11. Rapport Power BI final

Rapport Power BI - pages finales



12. Détail des pages du rapport

12.1 Vue Direction

Page de synthèse destinée à une lecture rapide par la direction. Elle regroupe les KPI clés, l'évolution du revenu, les agences les plus productives et les principaux canaux ou types de transactions.

- Revenu réalisé.
- Production de crédit.
- Nouveaux clients.
- Taux d'impayé.
- Taux de réalisation de la production de crédit.

12.2 Performance commerciale

Analyse de l'activité transactionnelle et de la production commerciale.

- Évolution mensuelle des transactions.
- Débits et crédits par mois.
- Production de crédit par type.
- Répartition des transactions par canal.

12.3 Analyse clients

Analyse des profils, revenus, risques et usages produits.

- Clients distincts et revenu mensuel moyen.
- Répartition par segment.
- Tranches de revenu avec dégradé de couleur.
- Niveaux de risque colorés faible / modéré / élevé.
- Top 10 des produits les plus utilisés.

12.4 Risque crédit

Suivi opérationnel des remboursements et identification des agences à surveiller.

- Nombre d'échéances et d'impayés.
- Taux d'impayé et montant non payé.
- Montants attendus et payés.
- Taux de retard par agence.
- Tableau de surveillance avec mise en forme conditionnelle.

12.5 Pilotage des agences

Comparaison du réalisé et des objectifs pour le revenu, la production de crédit et les nouveaux clients.

- Réalisé en bleu et objectif en doré.
- Taux de réalisation colorés en rouge, orange ou vert.
- Écart de revenu par agence.
- Matrice de synthèse des performances.

12.6 Détail agence

Page secondaire accessible par clic droit et extraction. Elle reprend le contexte de l'agence choisie, affiche ses KPI, ses tendances mensuelles et ses indicateurs de risque, puis permet de revenir à la page précédente.

13. Design et expérience utilisateur

Usage	Couleur
Éléments institutionnels et titres	Bleu nuit.
Réalisé et activité principale	Bleu canard.
Objectifs	Doré.
Performance atteinte	Vert.
Vigilance	Orange.
Retard, impayé ou écart négatif	Rouge.

- Segments en liste déroulante et alignements homogènes.
- Cartes KPI sur fond blanc avec bordures discrètes.
- Titres courts et cohérents sur toutes les pages.
- Info-bulles enrichies pour éviter de surcharger les visuels.
- Navigation principale et page de détail masquée.
- Page de contrôles conservée mais masquée.

14. Validation et fiabilité

14.1 Contrôles croisés SQL / Power BI

- Comparaison des volumes et des totaux entre mart et Power BI.
- Vérification des mois dans l'ordre chronologique.
- Vérification des relations de dates principales et secondaires.
- Exclusion contrôlée des valeurs vides et des membres inconnus dans les visuels.
- Test des segments Année, Mois, Catégorie d'agence, Agence, Segment et Risque.
- Test du drill-through Détail agence et du bouton Précédent.

14.2 Quelques contrôles métier observés

Indicateur	Valeur de contrôle
Échéances de remboursement	18 899
Impayés	103
Taux d'impayé	Environ 0,55 %
Retards	7 282
Taux de retard	Environ 38,53 %
Montant total des débits	Environ 1,224 M€
Montant total des crédits	Environ 1,097 M€

Interprétation - Les taux d'impayé et de retard ne mesurent pas la même situation. Leur distinction a été vérifiée dans les formules DAX et les visuels.

15. Compétences démontrées

Compétence	Démonstration dans le projet
SQL Server / T-SQL	Création de base, schémas, tables, imports, contrôles, nettoyage, dimensions, faits et index.
Qualité des données	Détection des anomalies, déduplication, gestion des orphelins et conservation du brut.
Modélisation	Architecture raw/staging/mart et modèle en étoile avec grains explicites.
Power Query	Types, profilage, colonnes de présentation et organisation des requêtes.
DAX	Mesures dynamiques, ratios, comparaisons temporelles et USERELATIONSHIP.
Data visualisation	Pages orientées décision, navigation, info-bulles et mise en forme conditionnelle.
Documentation	Scripts commentés, PDF, README, structure GitHub et pitch entretien.